


Symphonie Arctique

Création de la trame sonore IA

Deux versions livrées à partir des données de température du sol de Tasiujaq



Résumé. Nous transformons 27 années de données journalières de température du sol de Tasiujaq (1993–2023) en deux pièces orchestrales complémentaires de 3 minutes. Les deux pièces partagent les mêmes sept voix musicales (une par profondeur de sol entre 200 cm et 1100 cm), le même choix d'instrumentation guidé par texte, et la même étape de mise en forme par enveloppe. Elles diffèrent dans la manière dont les données se couplent à l'audio généré :

Version 1, sonification modulée par enveloppe. Le signal du sol sculpte chaque voix par un effet audio dédié : intensité, brillance, largeur stéréo, trémolo ou coupure de basses. Chaque voix exprime donc les données dans une dimension sensorielle différente.

Version 2, sonification ancrée par accord microtonal. En plus des effets d'enveloppe, le contenu harmonique microtonal de chaque profondeur (extrait par décomposition modale empirique, EMD) est injecté directement dans le processus de diffusion du modèle d'IA comme amorce. Les hauteurs générées par le modèle sont alors biaisées vers l'accord réel de la profondeur. Les données se couplent ainsi à la musique à la fois dans le temps (enveloppe) et dans le spectre (accord).

Table des matières

1	Les données source	1
2	De la profondeur à la voix	1
3	Cartographier 27 années sur 3 minutes	2
4	Le mécanisme partagé : l'extraction d'enveloppe	3
5	Version 1 : sonification modulée par enveloppe	5
5.1	Acheminement des effets par profondeur	5
5.2	Implémentation	5
6	Version 2 : sonification ancrée par accord microtonal	6
6.1	L'accord d'amorçage	6
6.2	Comment l'amorce entre dans la diffusion	7
6.3	Ce qui est partagé avec la Version 1	8
7	Assemblage : enchaînement et mixage	9
8	Feuille de route	9
8.0.1	Enveloppes multi-IMF	9
8.0.2	Voie B : génération conditionnée par enveloppe	9
8.0.3	Voie B ⁺ : conditionnement multi-cible	10

1 Les données source

L'entrée est un fichier CSV de températures du sol mesurées à quatorze profondeurs, entre 0 cm (surface) et 1100 cm (onze mètres sous terre), à Tasiujaq, Nunavik. Les mesures sont journalières et couvrent 26,7 années (9 748 jours, d'août 1993 à 2023). Sept des quatorze profondeurs ont une couverture suffisamment continue pour être utilisables dans la pièce : 200, 300, 400, 500, 700, 900 et 1100 cm.

Les profondeurs racontent des histoires physiques radicalement différentes. Près de la surface, le sol suit les saisons de manière agressive : le réchauffement estival pousse les températures au-dessus de +20 °C, tandis que l'air hivernal les fait chuter sous -30 °C. La chaleur diffuse lentement dans le sol, donc chaque mètre supplémentaire de profondeur lisse et retarde ce signal. À 11 m de profondeur, les températures oscillent étroitement entre -5 et -4 °C toute l'année. C'est le pergélisol, presque immobile sur les 27 années de l'enregistrement.

Une entrée complémentaire est aussi disponible : une décomposition modale empirique (Empirical Mode Decomposition, EMD) du même signal de sol, exportée en fichier MIDI microtonal. Pour chaque profondeur utilisable, l'analyse EMD produit 8 à 11 fréquences réparties sur environ huit octaves, soit un « accord » par profondeur qui caractérise sa structure harmonique interne. La plus basse de ces fréquences se situe toujours autour de 28–32 Hz ; cette fondamentale sub-grave commune reflète la tendance pluridécennale de la température, à laquelle toutes les profondeurs finissent par répondre.

■ *Sol volatil → voix expressive. Sol stable → bourdon.*

2 De la profondeur à la voix

Chacune des sept profondeurs utilisables se voit attribuer sa propre voix musicale : un instrument ou une couche vocale décrits en prose et fournis au modèle d'IA comme prompt textuel. Les voix sont délibérément réparties sur des bandes de fréquences et des rôles distincts, pour qu'elles se superposent de manière transparente au lieu de se gêner dans une même plage.

Per-depth voice assignment			
Depth	Physical character	Musical voice (v10)	Role
200 cm	Volatile (std ~ 3.4 °C)	Soft soprano + celesta	Melodic top voice
300 cm	Volatile (std ~ 2.1 °C)	Piano + warm Rhodes	Melodic mid voice
400 cm	Moderate (std ~ 1.2 °C)	Muted viola + humming	Lead lament
500 cm	Moderate (std ~ 1.1 °C)	Wordless choir	Harmonic pad
700 cm	Stable (std ~ 0.7 °C)	Taiko + pizzicato cello	Rhythmic build
900 cm	Stable (std ~ 0.36 °C)	Cello section + male bass	Low foundation
1100 cm	Near-frozen (std ~ 0.36 °C)	Permafrost + throat singing	Sub-bass drone

Figure 1. Attribution des voix par profondeur, partagée par les deux versions. Les tons chauds en haut sont les plus expressifs et mélodiques ; les tons froids en bas tiennent le bourdon de fondation. Les pistes de surface contiennent les éléments les plus délicats et transitoires (voix, célesta) ; les pistes profondes sont soutenues et dans le registre grave.

3 Cartographe 27 années sur 3 minutes

La sortie maximale architecturale du modèle audio par IA est de 47 secondes. Pour produire une pièce de 3 minutes, nous découpons l’audio en quatre segments de 47 secondes superposés par fondu enchaîné (fondus à puissance constante de 3 secondes, donnant $4 \times 47 - 3 \times 3 \approx 179$ s). Nous tirons parti de cette contrainte : chaque segment est alimenté par une tranche différente d’environ 6,7 années du signal de sol, de sorte que la tendance pluridécennale de réchauffement est inscrite dans la progression musicale.

Time mapping — 27 years → 3 minutes




Figure 2. Cartographie temporelle. Les 27 années d’enregistrement sont divisées en quatre fenêtres d’environ 6,7 années. Chaque fenêtre pilote un segment audio d’environ 47 s ; les quatre segments sont ensuite reliés par fondu enchaîné dans la pièce finale d’environ 3 minutes. Les descripteurs de prompt évoluent en parallèle : « intact » au début, « dégel actif » au milieu, « réchauffement tardif » à la fin.

Parce que chaque segment de 47 secondes est piloté par environ 6,7 années de données journalières, chaque segment contient environ sept cycles saisonniers du signal de sol. L’enveloppe oscille donc à la fois à une échelle pluriannuelle lente (la tendance climatique) et à une échelle annuelle plus rapide (les saisons) dans chaque fenêtre de 47 secondes.

4 Le mécanisme partagé : l’extraction d’enveloppe

Les deux versions partagent la même première étape : pour chaque profondeur et chaque segment, la courbe réelle de température est convertie en une enveloppe, soit une courbe unique dans $[0, 1]$ qui suit le signal du sol dans le temps. C’est cette enveloppe qui sculpte l’audio généré par l’IA dans la deuxième étape.




Figure 3. La transformation en trois étapes, profondeur 200 cm, premier segment (1993–2000). (a) Environ 6,7 années de données de température journalière. Sept cycles saisonniers sont clairement visibles. Les pointillés verticaux marquent le 1^{er} janvier ; les creux tombent vers janvier (hiver), les pics au milieu d’année (été). (b) La même forme est normalisée dans $[0, 1]$, lissée, et rééchantillonnée sur la grille temporelle audio ; chaque année occupe environ 7 secondes dans le segment de 47 secondes. (c) L’enveloppe sculpte un signal audio synthétisé : intensité et autres effets respirent au rythme des saisons.

L’audio que l’enveloppe vient mettre en forme est produit par Stable Audio Open 1.0, un modèle texte-vers-audio à poids ouverts exécuté localement sur un seul GPU. Pour chaque couple profondeur $\times$ segment, nous écrivons un prompt sur mesure décrivant l’instrument de la voix, son registre et son humeur propre au segment. Avec sept profondeurs et quatre segments par profondeur, le modèle est invoqué 28 fois par pièce. La génération est déterministe pour une graine aléatoire fixée.

5 Version 1 : sonification modulée par enveloppe

Version 1 en une ligne. L’IA génère chaque voix à partir d’un prompt textuel. L’enveloppe de température de la profondeur pilote ensuite un effet audio signature sur cette voix, choisi pour que chaque voix exprime les données dans une dimension sensorielle différente.

5.1 Acheminement des effets par profondeur

L’enveloppe d’amplitude est toujours appliquée (l’intensité monte et descend avec la chaleur). En plus, chaque profondeur reçoit un effet supplémentaire adapté à sa voix. L’acheminement est intentionnel : les voix mélodiques et brillantes reçoivent un effet qui fait varier leur brillance ou leur présence spatiale ; les bourdons de fondation reçoivent un effet sur les basses qui permet d’entendre la basse « dégeler » à mesure que le sol se réchauffe ; les voix rythmiques gardent uniquement l’amplitude, pour que l’auditeur sente encore clairement le rythme.

Profondeur	Voix	Effet piloté par l’enveloppe (froid → chaud)
200 cm	Soprano + célesta	Largeur stéréo. Intime ↔ large.
300 cm	Piano + Rhodes chaleureux	Coupure passe-bas. Étouffée ↔ brillante.
400 cm	Alto en sourdine + voix fredonnée	Profondeur de trémolo. Stable ↔ vibrant.
500 cm	Chur sans paroles	Largeur stéréo. Étroite ↔ large.
700 cm	Taiko + voix de basse masculine	Aucun (amplitude seule, pour préserver la clarté rythmique).
900 cm	Violoncelles + voix de basse	Coupure passe-haut. Graves coupés ↔ pleins.
1100 cm	Pergélisol + chant diphonique	Aucun (amplitude seule, bourdon subtil).

5.2 Implémentation

Tous les filtres pilotés par l’enveloppe sont implémentés comme un fondu échantillon par échantillon entre une version pré-filtrée et le signal original, ce qui évite les transitoires audibles qu’un filtrage IIR par blocs produirait quand la fréquence de coupure varie rapidement. Le trémolo est un LFO basse fréquence dont la profondeur est modulée par l’enveloppe (stable au froid, vibrant au chaud). La largeur stéréo module le rapport mid/side.

La même courbe de température sculpte sept voix, chacune à sa façon.

6 Version 2 : sonification ancrée par accord microtonal

Version 2 en une ligne. Mêmes effets d'enveloppe que la Version 1, plus : l'accord microtonal issu de l'EMD pour cette profondeur est fourni au modèle d'IA comme amorce du processus de diffusion. Les hauteurs générées par le modèle sont biaisées vers cet accord. Les données se couplent ainsi à la musique à la fois dans le temps et dans le spectre.

6.1 L'accord d'amorçage

Pour chaque profondeur, les partiels extraits du MIDI microtonal sont synthétisés comme un signal stéréo de 47 secondes par sommation de sinusoides. Les partiels au-dessus de 2 kHz sont écartés (ils injecteraient un contenu aigu agressif) et les partiels restants sont pondérés pour que les fréquences les plus basses dominant.

Version 2 — Microtonal chord seeding of the diffusion process

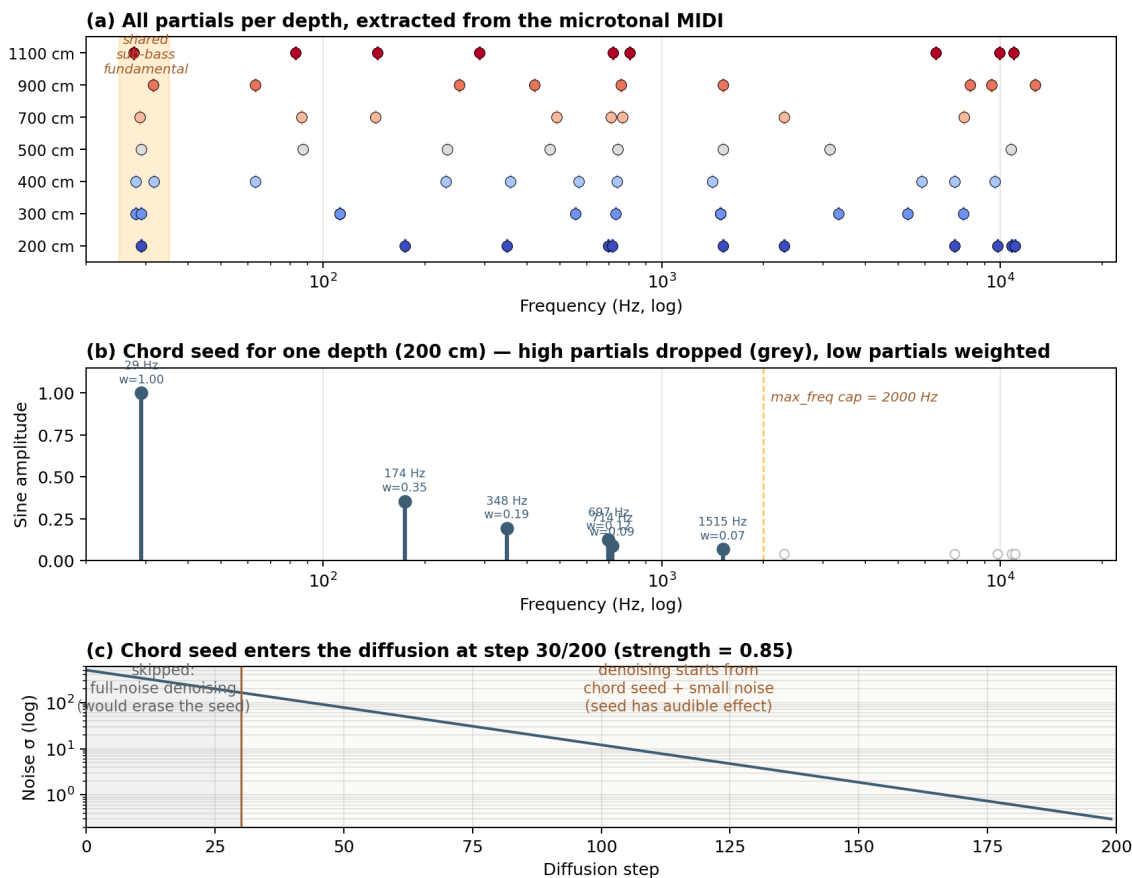


Figure 4. Construction et intégration de l’amorce d’accord pour la Version 2. (a) Ensemble complet des partiels par profondeur, tels qu’extraits du MIDI microtonal. La bande orange marque la fondamentale sub-grave commune autour de 30 Hz qui relie les sept profondeurs en une seule famille harmonique. (b) Pour une profondeur (200 cm), les partiels conservés (en bleu) et écartés (en gris) après la coupure des aigus, avec les amplitudes utilisées dans la synthèse additive. (c) Là où l’amorce entre dans le processus de diffusion : au lieu de débruiter à partir de l’étape de bruit maximal (ce qui effacerait l’amorce), nous sautons les premiers 85 % du calendrier de bruit et démarrons le débruitage à partir d’un bruit beaucoup plus faible. L’amorce a alors un effet audible sur le spectre final.

6.2 Comment l’amorce entre dans la diffusion

Dans une génération texte-vers-audio standard, le modèle part d’un bruit pur et débruite progressivement jusqu’à un audio qui correspond au prompt textuel. Quand on fournit un audio initial, le pipeline standard ajoute quand même un bruit de pleine amplitude par-dessus avant la première étape de débruitage, ce qui efface presque toute influence de l’amorce. La Version 2 utilise une variante de type img2img : le bruit ajouté à l’amorce encodée est dimensionné à un niveau bien plus faible, et la boucle de débruitage est raccourcie pour partir de ce point. Le modèle opère désormais sur une représentation latente qui est réellement une version bruitée de l’accord, et sa trajectoire de débruitage est attirée vers le spectre de l’accord.

Un seul paramètre, la force (strength), contrôle le compromis : à force = 1,0 l’amorce est ignorée (comportement standard) ; à des valeurs plus faibles, le modèle est de plus en plus contraint au

spectre de l'amorce. En pratique, nous utilisons force $\approx 0,85$, valeur à laquelle l'amorce façonne le spectre sans écraser le contenu créatif du modèle.

6.3 Ce qui est partagé avec la Version 1

Le tableau d'acheminement multi-effet par profondeur de la Section 5 est appliqué tel quel à l'audio de la Version 2. L'amorce façonne les notes que joue le modèle ; les effets d'enveloppe façonnent ensuite comment ces notes sont entendues dans le temps. Les données se couplent à la musique dans deux dimensions orthogonales.

7 Assemblage : enchaînement et mixage

Les quatre segments de chaque profondeur sont reliés par fondu enchaîné (fondus à puissance constante de 3 secondes) en un flux unique d'environ 3 minutes. Les sept flux sont ensuite équilibrés en intensité et sommés dans le mixage final. La même étape d'assemblage est utilisée pour les deux versions.




Figure 5. Équilibre du mixage. Les sept flux et leurs gains finaux dans les mixages livrés. Les pistes éparées ou transitoires (par exemple les taiko ou la sub-basse du pergélisol) reçoivent des amplifications plus fortes (jusqu'à +12 dB) pour rejoindre perceptivement les pistes denses et soutenues (comme le chœur). Les valeurs en dB à côté de chaque piste sont le gain total appliqué par un processus en deux étapes : égalisation RMS (qui remonte les pistes éparées au niveau cible commun) et un petit ajustement manuel de fader par piste.

8 Feuille de route

Enveloppes multi-IMF. Le signal de température de chaque profondeur peut lui-même être décomposé par EMD en une courte liste de composantes fréquentielles (journalière, saisonnière, pluriannuelle). Acheminer différents IMFs vers des effets différents sur une même voix (par exemple la tendance pluriannuelle pilotant la coupure du filtre et le cycle saisonnier pilotant l'intensité) donnerait trois flux de contrôle pilotés par les données par profondeur au lieu d'un seul. Aucun calcul d'IA supplémentaire nécessaire ; seulement une itération de l'étape de mise en forme par enveloppe.

Voie B : génération conditionnée par enveloppe. Une extension plus ambitieuse consiste à faire en sorte que l'IA elle-même planifie ses dynamiques pour que la courbe d'intensité naturelle de l'audio généré corresponde déjà à l'enveloppe du sol, plutôt que d'appliquer l'enveloppe après coup. C'est réalisable par optimisation au moment de l'inférence du bruit latent initial (méthodes de type DITTO). Le coût en calcul est environ 10× le pipeline actuel.

Voie B⁺ : conditionnement multi-cible. La même optimisation à l'inférence peut viser à la fois l'enveloppe et le spectre simultanément, en utilisant l'amorce d'accord comme cible spectrale et la courbe de température comme cible d'enveloppe. Cela unifierait les Versions 1 et 2 en une seule passe de conditionnement plutôt qu'un pipeline en deux étapes.

Provenance. Données source : surveillance du pergélisol à Tasiujaq (1993–2023). Modèle audio : Stable Audio Open 1.0 (Stability AI). Implémentation du pipeline : ce projet, Python 3.12 avec `diffusers`, `scipy`, `matplotlib`. Mise en page $\text{\LaTeX}$ (Tectonic), Linux Libertine.

Fichiers livrés. Version 1 : `outputs/mix_3min_v10_3_balanced.wav`.

Version 2 : `outputs/mix_3min_v15_2_balanced.wav`.